

Tutoriel SILLON

SILLON — Tutoriel de découverte

SQL progressif, Python et R avancés sur un jeu de données réel

À propos de ce tutoriel

Ce document accompagne le compte de démonstration `demo@sillon.local` créé par le paquet `sillon-tutoriel`. Il vous fait découvrir SILLON à travers un vrai jeu de données ouvert, avec des exercices SQL en difficulté croissante, puis un panorama complet de ce qu’il est possible de produire en Python et en R : graphiques, tableaux, exports Excel, rapports PDF, cartographie et diagrammes Mermaid — le tout démontré une seconde fois à grande échelle (43,9 millions de lignes) si le paquet optionnel `sillon-demo-sirene` est également installé (Parties 4 et 5).

Identifiants du compte de démonstration

Champ	Valeur
Adresse email	<code>demo@sillon.local</code>
Mot de passe	<code>demo</code>
Profil	Agent

Ce mot de passe est volontairement fixe et documenté, pour faciliter une session de démonstration ou de formation. Le paquet `sillon-tutoriel` ne doit **jamais** être installé sur un serveur de production — voir le guide d’installation administrateur, §7.2.

Tous les scripts présentés dans ce tutoriel sont téléchargeables, sous forme de fichiers réellement fonctionnels (pas de simples extraits) — qu’il s’agisse des scripts d’exemple déjà exécutés à l’installation ou des corrigés d’exercices. Depuis le bouton « À propos » de l’application, connecté avec le compte de démonstration : archive `corriges-tutoriel.zip`, organisée en `sql/`, `python/exemples/`, `python/exercices/`, `r/exemples/` et `r/exercices/`.

Le jeu de données

Trois tables sont déjà importées dans votre base personnelle :

- `communes_france` — 34 868 communes de France (métropole et outre-mer), avec pour chacune : son département, sa région, sa population, sa superficie, sa densité, son altitude et ses coordonnées.
- `regions_france` — les 18 régions françaises et le code INSEE de leur chef-lieu (préfecture de région), pour pratiquer les jointures.
- `contours_departements` — les frontières réelles des 104 départements français (métropole et outre-mer), sous forme de points ordonnés, pour la cartographie (partie 4).

Sources : jeu de données « Communes et villes de France », publié sur data.gouv.fr, construit à partir des données officielles de l’INSEE et de l’IGN ; contours départementaux issus de l’**IGN ADMIN EXPRESS**. Les deux sont diffusés sous **Licence Ouverte / Open Licence version 2.0** (Etalab).

Colonnes de `communes_france` :

Colonne	Type	Description
<code>code_insee</code>	Texte	Code INSEE de la commune
<code>nom_standard</code>	Texte	Nom de la commune
<code>dep_code</code>	Texte	Code du département
<code>dep_nom</code>	Texte	Nom du département
<code>reg_code</code>	Texte	Code de la région
<code>reg_nom</code>	Texte	Nom de la région
<code>population</code>	Entier	Population municipale
<code>superficie_km2</code>	Décimal	Superficie en km ²
<code>densite</code>	Décimal	Densité en habitants/km ²
<code>altitude_moyenne</code>	Entier	Altitude moyenne en mètres
<code>latitude_centre / longitude_centre</code>	Décimal	Coordonnées du centre de la commune

Colonnes de `regions_france` : `reg_code`, `reg_nom`, `chef_lieu_nom`, `chef_lieu_code_insee`.

Colonnes de `contours_departements` : `dep_code`, `dep_nom`, `groupe` (numéro d'anneau — un département avec des îles a plusieurs anneaux), `ordre` (position du point dans l'anneau), `longitude`, `latitude`.

Partie 1 — SQL progressif

Tous les exercices se travaillent dans l'onglet **Travaux**, en sélectionnant votre base personnelle. Les sept premiers exercices sont déjà présents dans votre **historique** (onglet Travaux) : vous pouvez les relire ou les réexécuter avant de passer aux suivants, qui restent à écrire vous-même. Corrigés téléchargeables dans `sql/` (`exercice_1.3.sql` à `exercice_7.2.sql`).

Niveau 1 — Sélection et filtrage

1.1. Affichez toutes les communes du département du Rhône (code 69).

```
SELECT * FROM communes_france WHERE dep_code = '69';
```

1.2. Affichez uniquement le nom et la population des communes de plus de 50 000 habitants.

```
SELECT nom_standard, population FROM communes_france WHERE population > 50000;
```

1.3. À vous de jouer : affichez les communes de moins de 100 habitants situées en Corse (code région 94).

Corrigé

```
SELECT nom_standard, dep_nom, population
FROM communes_france
WHERE reg_code = '94' AND population < 100;
```

Niveau 2 — Tri et limitation

2.1. Les 10 communes les plus peuplées de Bretagne (code région 53).

```
SELECT nom_standard, population
```

```
FROM communes_france
WHERE reg_code = '53'
ORDER BY population DESC
LIMIT 10;
```

2.2. À vous de jouer : les 5 communes les plus hautes en altitude de France (attention aux valeurs manquantes : altitude_moyenne n'est pas toujours renseignée).

Corrigé

```
SELECT nom_standard, dep_nom, altitude_moyenne
FROM communes_france
WHERE altitude_moyenne IS NOT NULL
ORDER BY altitude_moyenne DESC
LIMIT 5;
```

Niveau 3 — Agrégations

3.1. Nombre de communes et population totale du département de la Gironde (33).

```
SELECT COUNT(*) AS nb_communes, SUM(population) AS population_totale
FROM communes_france
WHERE dep_code = '33';
```

3.2. Population totale et nombre de communes par département, triés par population décroissante.

```
SELECT dep_nom, COUNT(*) AS nb_communes, SUM(population) AS population_totale
FROM communes_france
GROUP BY dep_nom
ORDER BY population_totale DESC;
```

3.3. À vous de jouer : la densité moyenne par région, arrondie à une décimale.

Corrigé

```
SELECT reg_nom, ROUND(AVG(densite)::numeric, 1) AS densite_moyenne
FROM communes_france
GROUP BY reg_nom
ORDER BY densite_moyenne DESC;
```

Niveau 4 — Filtrer sur un agrégat (HAVING)

4.1. Les régions dont la densité moyenne dépasse 200 habitants/km².

```
SELECT reg_nom, ROUND(AVG(densite)::numeric, 1) AS densite_moyenne
FROM communes_france
GROUP BY reg_nom
HAVING AVG(densite) > 200
ORDER BY densite_moyenne DESC;
```

4.2. À vous de jouer : les départements comptant plus de 500 communes.

Corrigé

```
SELECT dep_nom, COUNT(*) AS nb_communes
FROM communes_france
GROUP BY dep_nom
HAVING COUNT(*) > 500
ORDER BY nb_communes DESC;
```

Niveau 5 — Sous-requêtes

5.1. Les communes plus peuplées que la moyenne nationale.

```
SELECT nom_standard, dep_nom, population
FROM communes_france
WHERE population > (SELECT AVG(population) FROM communes_france)
ORDER BY population DESC;
```

5.2. À vous de jouer : pour chaque région, la commune la plus peuplée (indice : une sous-requête corrélée, ou une fonction de fenêtrage — voir niveau 7).

Corrigé (sous-requête corrélée)

```
SELECT c.nom_standard, c.reg_nom, c.population
FROM communes_france c
WHERE c.population = (
    SELECT MAX(c2.population) FROM communes_france c2 WHERE c2.reg_nom = c.reg_nom
)
ORDER BY c.population DESC;
```

Niveau 6 — Jointures

6.1. Pour chaque région, la population de son chef-lieu (jointure avec `regions_france`).

```
SELECT c.nom_standard AS commune, c.population AS population_chef_lieu, r.reg_nom
FROM communes_france c
JOIN regions_france r ON c.code_insee = r.chef_lieu_code_insee
ORDER BY c.population DESC;
```

6.2. À vous de jouer : la part de la population régionale que représente le chef-lieu (combinez la requête ci-dessus avec une agrégation de population par région).

Corrigé

```
WITH population_regions AS (
    SELECT reg_nom, SUM(population) AS population_totale
    FROM communes_france
    GROUP BY reg_nom
)
SELECT
    c.nom_standard AS chef_lieu,
    c.population AS population_chef_lieu,
    pr.population_totale,
    ROUND(100.0 * c.population / pr.population_totale, 1) AS part_pourcent
FROM communes_france c
JOIN regions_france r ON c.code_insee = r.chef_lieu_code_insee
JOIN population_regions pr ON pr.reg_nom = r.reg_nom
ORDER BY part_pourcent DESC;
```

Niveau 7 — Fonctions de fenêtrage (avancé)

7.1. Le classement de chaque commune par population, au sein de son département (`RANK() OVER`).

```
SELECT
    nom_standard, dep_nom, population,
    RANK() OVER (PARTITION BY dep_code ORDER BY population DESC) AS
rang_departemental
FROM communes_france
ORDER BY dep_nom, rang_departemental;
```

7.2. À vous de jouer : ne garder que la commune la plus peuplée de chaque département (indice : enveloppez la requête précédente et filtrez sur `rang_departemental = 1`).

Corrigé

```

SELECT * FROM (
    SELECT
        nom_standard, dep_nom, population,
        RANK() OVER (PARTITION BY dep_code ORDER BY population DESC) AS
rang_departemental
    FROM communes_france
) classement
WHERE rang_departemental = 1
ORDER BY population DESC;

```

Pour aller plus loin : le délai maximal d’une requête est limité (§11) ; une requête plus longue peut être basculée en tâche de fond (bouton « Exécuter en tâche de fond »), avec notification par mail à la fin — utile si vous étendez ces exercices à des calculs plus lourds.

Partie 2 — Python avancé

L’onglet **Scripts** permet de déposer un fichier .py ou .R, exécuté dans un environnement isolé avec un accès direct à votre base (variable d’environnement SILLON_DSN) et un répertoire de sortie pour vos résultats (SILLON_RESULTATS). Bibliothèques Python disponibles : pandas, numpy, matplotlib, psycpg2, openpyxl — consultez la liste à jour dans l’onglet avant de coder. Pas de bibliothèque géospatiale (geopandas, shapely) ni de graphiques interactifs (plotly, bokeh) : tout export est une image statique ou un fichier.

Squelette commun à tous les scripts de cette partie :

```

import os
import psycpg2
import pandas as pd

dsn = os.environ["SILLON_DSN"]
resultats = os.environ["SILLON_RESULTATS"]

connexion = psycpg2.connect(dsn)
communes = pd.read_sql("SELECT * FROM communes_france", connexion)
connexion.close()

# ... votre analyse, vos graphiques, vos exports ...

```

2.1 Panorama des graphiques (matplotlib)

matplotlib.use("Agg") est **obligatoire** en tout début de script (avant import matplotlib.pyplot) : aucun affichage interactif n’est possible dans le conteneur d’exécution.

Graphique	Fonction	Usage typique
Courbe	ax.plot(x, y)	évolution le long d’une variable continue
Barres	ax.bar(x, y) / ax.barh(x, y)	comparaison de catégories (verticale/horizontale)
Nuage de points	ax.scatter(x, y)	relation entre deux variables
Histogramme	ax.hist(valeurs, bins=...)	distribution d’une variable
Camembert	ax.pie(valeurs, labels=...)	répartition en proportions (à réserver à moins de 6 catégories, sinon illisible)

Graphique	Fonction	Usage typique
Boîte à moustaches	<code>ax.boxplot([groupe1, groupe2, ...])</code>	comparer la dispersion entre groupes
Carte de chaleur	<code>ax.imshow(matrice, cmap=...)</code>	matrice de valeurs (corrélations, tableaux croisés)
Plusieurs graphiques	<code>fig, axes = plt.subplots(2, 2)</code>	tableau de bord en une seule image


Exemple : une carte de chaleur des corrélations entre les variables numériques de `communes_france`.

```
import matplotlib
matplotlib.use("Agg")
import matplotlib.pyplot as plt

colonnes_numeriques = ["population", "superficie_km2", "densite",
"altitude_moyenne"]
correlations = communes[colonnes_numeriques].corr()

figure, axe = plt.subplots(figsize=(6, 5))
image = axe.imshow(correlations, cmap="coolwarm", vmin=-1, vmax=1)
axe.set_xticks(range(len(colonnes_numeriques)), colonnes_numeriques, rotation=45,
ha="right")
axe.set_yticks(range(len(colonnes_numeriques)), colonnes_numeriques)
plt.colorbar(image, ax=axe, label="Corrélation")
figure.savefig(os.path.join(resultats, "correlations.png"), bbox_inches="tight")
```

Le script d'exemple `exemple_2.1_panorama_graphiques.py` (déjà déposé et exécuté, résultat dans l'onglet **Suivi** ; téléchargeable dans `python/exemples/`) combine barres horizontales, barres verticales et histogramme en échelle logarithmique sur les 34 868 communes.



Population totale par région, résultat réel de `exemple_2.1_panorama_graphiques.py`

2.2 Tableaux et export Excel

Un tableau croisé avec `pandas.pivot_table` :

```

tableau = communes.pivot_table(
    index="reg_nom", values="population", aggfunc=["count", "sum", "mean"]
)

```

Export vers un vrai classeur Excel avec `openpyxl` (installé, pas seulement `pandas.to_csv`) : plusieurs onglets, mise en forme des cellules, et même des **graphiques natifs Excel** (pas une image collée) :

```

from openpyxl import Workbook
from openpyxl.chart import BarChart, Reference
from openpyxl.styles import Font

classeur = Workbook()
feuille = classeur.active
feuille.title = "Population par région"

par_region = communes.groupby("reg_nom")
["population"].sum().sort_values(ascending=False)
feuille.append(["Région", "Population"])
feuille["A1"].font = feuille["B1"].font = Font(bold=True)
for region, population in par_region.items():
    feuille.append([region, int(population)])

graphique = BarChart()
graphique.title = "Population par région"
donnees = Reference(feuille, min_col=2, min_row=1, max_row=feuille.max_row)
categories = Reference(feuille, min_col=1, min_row=2, max_row=feuille.max_row)
graphique.add_data(donnees, titles_from_data=True)
graphique.set_categories(categories)
feuille.add_chart(graphique, "D2")

classeur.save(os.path.join(resultats, "rapport.xlsx"))

```

2.3 Rapports PDF multi-pages

`matplotlib.backends.backend_pdf.PdfPages` assemble plusieurs graphiques dans un seul PDF, une page par figure — pratique pour un rapport complet en une seule pièce jointe :

```

from matplotlib.backends.backend_pdf import PdfPages

with PdfPages(os.path.join(resultats, "rapport.pdf")) as pdf:
    figure1, axe1 = plt.subplots()
    axe1.hist(communes["densite"].dropna(), bins=50)
    axe1.set_title("Distribution de la densité")
    pdf.savefig(figure1)
    plt.close(figure1)

    figure2, axe2 = plt.subplots()
    axe2.bar(par_region.index, par_region.values)
    axe2.set_title("Population par région")
    plt.xticks(rotation=60, ha="right")
    pdf.savefig(figure2, bbox_inches="tight")
    plt.close(figure2)

```

2.4 Cartographie

Pas de `geopandas/shapely` dans l'image d'exécution : la table `contours_departements` aplatit volontairement chaque polygone en points ordonnés (`dep_code`, `groupe`, `ordre`, `longitude`, `latitude`) plutôt qu'un format géospatial — `matplotlib.patches.Polygon` sait tracer un polygone à partir d'une simple liste de coordonnées, sans dépendance supplémentaire.


Le script d'exemple `exemple_2.4_cartographie.py` (déjà déposé et exécuté, résultat dans l'onglet **Suivi** ; téléchargeable dans `python/exemples/`) trace une carte choroplèthe de la population par département :

```
from collections import defaultdict
from matplotlib.patches import Polygon
from matplotlib.collections import PatchCollection

contours = pd.read_sql(
    "SELECT dep_code, groupe, ordre, longitude, latitude FROM
    contours_departements ORDER BY dep_code, groupe, ordre",
    connexion,
)
polygones = defaultdict(list)
for ligne in contours.itertuples():
    polygones[(ligne.dep_code, ligne.groupe)].append((ligne.longitude,
    ligne.latitude))

patches = [Polygon(points, closed=True) for points in polygones.values()]
# ... couleur de chaque polygone selon la valeur de son département (cf. script
complet) ...
collection = PatchCollection(patches, cmap="Blues")

figure, axe = plt.subplots(figsize=(8, 8))
axe.add_collection(collection)
axe.autoscale_view()
axe.set_aspect("equal")
axe.axis("off")
figure.savefig(os.path.join(resultats, "carte.png"), bbox_inches="tight")
```




Carte choroplèthe de la population par département, résultat réel de `exemple_2.4_cartographie.py`

Exercices

Corrigés téléchargeables dans `python/exercices/` (`exercice_2.1.py` à `exercice_2.4.py`).

2.1. Reproduisez la carte de `exemple_2.4_cartographie.py`, mais coloriée par **densité moyenne** du département plutôt que par population totale.



Corrigé de l'exercice 2.1 : carte coloriée par densité moyenne

2.2. Exportez un fichier Excel avec un onglet par région, chacun listant les communes de la région triées par population, en utilisant `openpyxl` (indice : une feuille par valeur unique de `reg_nom`, via une boucle).


CommunePopulation

Lyon	519127
Saint-Étie	173136
Villeurban	163684
Grenoble	156140
Clermont-F	146351
Annecy	132117
Vénissieux	65502
Valence	64458
Chambéry	59964
Vaulx-en-V	53069
Saint-Pries	49229

Corrigé de l'exercice 2.2 : classeur Excel avec un onglet par région (ici, l'onglet Auvergne-Rhône-

Alpes, 10 premières lignes)

2.3. *Avancé* : assemblez en un seul PDF (PdfPages) trois graphiques de votre choix parmi ceux du panorama (2.1 ci-dessus).



Corrigé de l'exercice 2.3 : première page du rapport PDF (barres, camembert, histogramme assemblés)

2.4. *Avancé* : calculez, pour chaque région, le coefficient de corrélation entre altitude moyenne et densité (DataFrame.corr() après un groupby). Les régions de montagne sont-elles significativement moins denses ?

Résultat réel (correlation_altitude_densite.csv, extrait) :

Région	Corrélation
Île-de-France	-0,43
Provence-Alpes-Côte d'Azur	-0,34
Hauts-de-France	-0,30
Bretagne	-0,26
Corse	-0,23
Bourgogne-Franche-Comté	-0,06

Corrélations négatives partout : dans chaque région, les communes les plus hautes en altitude tendent à être les moins denses — hypothèse confirmée, à des degrés très variables selon la région.

Partie 3 — R avancé

Même contrat d'exécution qu'en Python (SILLON_DSN, SILLON_RESULTATS). Bibliothèques R disponibles : `tidyverse` (dont `dplyr`, `ggplot2`, `tidyr`, `readr`), `DBI`, `RPostgreSQL`. **Pas de** `jsonlite`, **sf** **ni** `openxlsx` dans l'image d'exécution : contrairement à Python, R ne peut donc pas écrire de fichier Excel ici — seulement du CSV (`write.csv`) et des graphiques.

Point d'attention : `RPostgreSQL::dbConnect()` n'accepte pas directement la chaîne de connexion `SILLON_DSN` (format clé=valeur de libpq) — il faut l'analyser vous-même :

```
library(DBI)
library(RPostgreSQL)
library(dplyr)
library(ggplot2)

analyser_dsn <- function(dsn) {
  valeurs <- list()
  for (paire in strsplit(trimws(dsn), "\\s+")[1]) {
    cle_valeur <- strsplit(paire, "=", fixed = TRUE)[1]
    valeurs[[cle_valeur[1]]] <- cle_valeur[2]
  }
  valeurs
}

parametres <- analyser_dsn(Sys.getenv("SILLON_DSN"))
resultats <- Sys.getenv("SILLON_RESULTATS")

connexion <- dbConnect(
  PostgreSQL(),
  host = parametres$host, port = as.integer(parametres$port),
  dbname = parametres$dbname, user = parametres$user, password =
parametres$password
)
communes <- dbGetQuery(connexion, "SELECT * FROM communes_france")
```


3.1 Panorama des graphiques (ggplot2)

Toujours la même grammaire : `ggplot(donnees, aes(...)) + geom_...() + ...`.

Graphique	Géométrie	Usage typique
Courbe	<code>geom_line()</code>	évolution le long d'une variable continue
Barres	<code>geom_col()</code> (valeurs déjà agrégées) / <code>geom_bar()</code> (comptage)	comparaison de catégories
Nuage de points	<code>geom_point()</code>	relation entre deux variables
Histogramme	<code>geom_histogram()</code>	distribution d'une variable
Boîte à moustaches	<code>geom_boxplot()</code>	comparer la dispersion entre groupes
Plusieurs graphiques	<code>facet_wrap(~ variable)</code>	un panneau par catégorie, échelle commune

```
graphique <- ggplot(communes, aes(x = densite)) +
  geom_histogram(bins = 50, fill = "#000091") +
  scale_x_log10() +
  facet_wrap(~ reg_nom) + # un histogramme par région
  theme_minimal()
ggsave(file.path(resultats, "densite_par_region.png"), graphique, width = 10,
height = 8)
```

Le script d'exemple `exemple_3.1_panorama_graphiques.R` (déjà exécuté, résultat dans l'onglet **Suivi** ; téléchargeable dans `r/exemples/`) trace la densité moyenne des 15 départements les plus denses et la relation altitude/densité.



Densité moyenne des 15 départements les plus denses, résultat réel de `exemple_3.1_panorama_graphiques.R`

3.2 Tableaux

```
tableau <- communes %>%
  group_by(reg_nom) %>%
  summarise(nb_communes = n(), population_totale = sum(population),
densite_moyenne = mean(densite, na.rm = TRUE)) %>%
  arrange(desc(population_totale))

write.csv(tableau, file.path(resultats, "tableau_regions.csv"), row.names = FALSE)
```

3.3 Rapports PDF multi-pages

Le périphérique graphique `pdf()` de R (toujours disponible, aucun package requis) écrit une nouvelle page à chaque graphique tracé entre son ouverture et `dev.off()` :

```
pdf(file.path(resultats, "rapport.pdf"), width = 8, height = 6)

hist(communes$densite, breaks = 50, main = "Distribution de la densité")

par_region <- communes %>% group_by(reg_nom) %>% summarise(population_totale =
sum(population))
```

```
barplot(par_region$population_totale, names.arg = par_region$reg_nom, las = 2,
        main = "Population par région")
```

```
dev.off()
```

3.4 Cartographie

Sans `sf` ni `maps` dans l'image d'exécution : `geom_polygon()` de `ggplot2` sait tracer un polygone directement à partir d'un data frame de points ordonnés (colonnes `x`, `y`, `group`) — le style « fortifié » classique de `ggplot2`, sans dépendance géospatiale.


Le script d'exemple `exemple_3.4_cartographie.R` (déjà déposé et exécuté, résultat dans l'onglet **Suivi** ; téléchargeable dans `r/exemples/`) trace la même carte choroplèthe qu'en Python :

```
contours <- dbGetQuery(
  connexion,
  "SELECT dep_code, groupe, ordre, longitude, latitude FROM contours_departements
  ORDER BY dep_code, groupe, ordre"
)
population_par_dep <- dbGetQuery(
  connexion, "SELECT dep_code, SUM(population) AS population_totale FROM
  communes_france GROUP BY dep_code"
)

contours <- contours %>%
  mutate(id_polygone = paste(dep_code, groupe, sep = "_")) %>%
  left_join(population_par_dep, by = "dep_code")

carte <- ggplot(contours, aes(x = longitude, y = latitude, group = id_polygone,
  fill = population_totale)) +
  geom_polygon(color = "white", linewidth = 0.1) +
  coord_fixed() +
  scale_fill_gradient(low = "#e8edfb", high = "#000091") +
  theme_void()
ggsave(file.path(resultats, "carte.png"), carte, width = 8, height = 8)
```

Population par département




Carte choroplèthe de la population par département, résultat réel de `exemple_3.4_cartographie.R`

Exercices


Corrigés téléchargeables dans `r/exercices/` (`exercice_3.1.R` à `exercice_3.4.R`).

3.1. Reproduisez la carte de `exemple_3.4_cartographie.R`, mais coloriée par densité moyenne plutôt que par population totale (indice : comparez à l'exercice Python 2.1).



Corrigé de l'exercice 3.1 : carte coloriée par densité moyenne

3.2. Avec `facet_wrap`, tracez un histogramme de la population des communes, un panneau par région.



Corrigé de l'exercice 3.2 : histogramme facetté, un panneau par région

3.3. Avancé : à l'aide de `regions_france`, faites une jointure (`inner_join`) entre les deux tables pour comparer, région par région, la population du chef-lieu à la population totale de la région — comme l'exercice SQL 6.2, mais en R.


Résultat réel (`part_chef_lieu.csv`, 5 premières lignes sur 18 régions) :

Chef-lieu	Région	Population du chef-lieu	Population totale	Part
Mamoudzou	Mayotte	71 437	256 518	27,8 %
Ajaccio	Corse	76 320	355 486	21,5 %
Cayenne	Guyane	62 675	293 996	21,3 %
Fort-de-France	Martinique	75 506	360 630	20,9 %
Paris	Île-de-France	2 103 778	12 463 067	16,9 %

Sans surprise, les chefs-lieux des petites régions ultramarines pèsent nettement plus lourd dans leur région que les grandes métropoles métropolitaines (Lyon : 6,3 %, Lille : 4 %) dans la leur.

3.4. Avancé : assemblez trois graphiques dans un seul rapport PDF avec `pdf()/dev.off()`.

Distribution de la densité (échelle log)



Corrigé de l'exercice 3.4 : première page du rapport PDF

Partie 4 — Python à grande échelle (sillon-demo-sirene)

Le paquet optionnel `sillon-demo-sirene` (complémentaire de `sillon-tutoriel`, à installer séparément — voir le guide d'installation administrateur, §7.2) importe le jeu de données Sirene complet de l'INSEE (« StockEtablissement », Licence Ouverte 2.0, data.gouv.fr) dans votre base personnelle : la table `sirene_etablisements`, environ **43,9 millions de lignes** — un ordre de grandeur au-delà de `communes_france`. Six scripts Python et trois scripts R, déjà déposés et exécutés à l'installation de ce paquet, démontrent les mêmes possibilités que les Parties 2 et 3 mais à cette échelle. **Si ce paquet n'est pas installé, cette table n'existe pas** : passez directement à « Pour continuer ».

Règle impérative à cette échelle : chaque script agrège côté PostgreSQL (`GROUP BY`, `COUNT`, ...) avant de rapatrier le résultat en Python/R — jamais un `SELECT * FROM sirene_etablisements` ni un `pd.read_sql("SELECT * FROM ...")` sans filtre, qui dépasserait largement le quota mémoire du conteneur d'exécution (`ram_max_conteneur_mo`, §11 du cahier des charges). Une requête déjà réduite à quelques dizaines ou centaines de lignes transite seule vers pandas/dplyr.

Colonnes de `sirene_etablisements` : `siren`, `siret`, `date_creation`, `tranche_effectifs`, `etablissement_siege` (booléen), `dep_code` (croisable avec `communes_france/contours_departements`), `etat_administratif` (A = actif), `activite_principale` (code NAF), `caractere_employeur` — volontairement réduit aux colonnes utilisées par les scripts de démonstration (chaque colonne

Texte ajoute un index de recherche approchée coûteux en espace disque à la construction, §7.4).

Scripts téléchargeables dans `python/` et `r/` (archive `corriges-sirene.zip`, modale « À propos »).

4.1 Panorama des graphiques (`graphiques_couverture.py`)

Quatre graphiques dans une seule image (`plt.subplots(2, 2)`) à partir de quatre requêtes agrégées : barres (établissements actifs par tranche d'effectif), camembert (part des employeurs), courbe (créations par année), barres horizontales (15 divisions NAF les plus représentées).

4.2 Tableau croisé (`tableau_pandas.py`)

Tableau croisé `pandas.pivot_table` (départements × tranches d'effectif, sur les 12 départements les plus dotés), exporté en CSV et en image de tableau (`ax.table`) — utile quand le résultat doit être consulté sans tableur.

4.3 Export Excel avec graphique natif (`export_excel.py`)

Classeur `openpyxl` à trois feuilles (résumé, top secteurs NAF, par département), avec un graphique natif Excel (`openpyxl.chart.BarChart`) directement modifiable dans Excel ou LibreOffice.

4.4 Rapport PDF multi-pages (`rapport_pdf_multipages.py`)

`PdfPages` assemble une page de garde (texte) et deux graphiques (évolution des créations, top 10 départements) en un seul PDF.

4.5 Diagramme Mermaid (`diagramme_mermaid.py`)

Le bac à sable n'a ni Node.js ni Chromium (§7.7/§8.7 du cahier des charges) : impossible d'y rendre une image Mermaid. Le script se contente d'écrire le **texte** Mermaid (`pie showData title ...`) dans ses résultats — SILLON le rend lui-même, côté navigateur, dès que vous ouvrez le bouton « **Aperçus** » du job dans l'onglet Suivi (à côté de « Journal » et « Télécharger »). Aucune bibliothèque supplémentaire requise, en Python comme en R : c'est la même mécanique que 4.5/5.3.

4.6 Cartographie croisée (`carte_choroplethe.py`)

Densité d'établissements actifs par département, sur les contours réels déjà importés par `sillon-tutoriel` (`contours_departements`) — les deux paquets partagent la même base personnelle, cette jointure ne nécessite donc aucun import supplémentaire.

Partie 5 — R à grande échelle (`sillon-demo-sirene`)

Même jeu de données et même règle d'agrégation SQL qu'en Partie 4.

5.1 Panorama des graphiques (`graphiques_ggplot.R`)

Trois graphiques `ggplot2` à partir de requêtes agrégées : barres (par tranche d'effectif), courbe (créations par année),

histogramme (distribution du nombre d'établissements actifs par département).

5.2 Pipeline dplyr (`analyse_dplyr.R`)

Classement des 20 divisions NAF les plus représentées (`mutate/arrange/row_number` sur un résultat déjà agrégé côté SQL), exporté en CSV.

5.3 Diagramme Mermaid (`diagramme_mermaid.R`)

Même principe qu'en 4.5 : le script écrit le texte Mermaid (répartition employeurs/non-employeurs), rendu côté navigateur depuis l'onglet Suivi.

Pour continuer

- Les onglets **Bases**, **Import** et **Suivi** couvrent le reste des fonctionnalités de SILLON : import de vos propres fichiers CSV, partage de base avec un autre compte, suivi et annulation des traitements en cours.
- Le **Guide d'installation administrateur** (accessible depuis le bouton « À propos ») détaille la configuration du serveur, les quotas et les procédures de désinstallation.
- Ce compte de démonstration peut être réinitialisé à tout moment : `sudo apt-get purge sillon-tutoriel && sudo apt-get install sillon-tutoriel` (voir le guide d'installation administrateur, §7.2 et §8).
- Si `sillon-demo-sirene` (Parties 4 et 5) n'est pas encore installé, il s'ajoute sans toucher au reste : `sudo dpkg -i sillon-demo-sirene_0.1.0_all.deb` (nécessite un accès Internet sur la machine cible le temps de l'installation — voir le guide d'installation administrateur, §7.2).